

# Apprentissage de modèles dynamiques

Marion Gilson

`marion.gilson@univ-lorraine.fr`

CRAN, Université de Lorraine – Polytech Nancy – France



# Outline

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

# Méthodes avancées d'identification des systèmes

## The players - Rappel

Système à identifier  $G_0$



- $u(t)$  est l'entrée (à temps discret) qui peut être choisie librement (sauf dans des cas type environnement)
- $y(t)$  est la sortie (à temps discret) qui est mesurée et provient de :
  - ◇ une contribution de l'entrée  $u(t)$ , c'est à dire  $G_0 u(t)$
  - ◇ une contribution indépendante de l'entrée  $u(t)$ , c'est à dire des perturbations  $v(t)$ .

# Méthodes avancées d'identification des systèmes

## The players - Rappel

Système à identifier  $G_0$



- $u(t)$  est l'entrée (à temps discret) qui peut être choisie librement (sauf dans des cas type environnement)
- $y(t)$  est la sortie (à temps discret) qui est mesurée et provient de :
  - ◇ une contribution de l'entrée  $u(t)$ , c'est à dire  $G_0 u(t)$
  - ◇ une contribution indépendante de l'entrée  $u(t)$ , c'est à dire des perturbations  $v(t)$ .

# Méthodes avancées d'identification des systèmes

## The players - Rappel

### Système à identifier $G_0$



- Le signal  $v(t)$  est une *perturbation inconnue* : bruit, perturbation, effets des entrées non mesurées,...
- $v(t)$  ne sera jamais identique dans le cas d'expériences répétées  
→ la meilleure estimation : processus stochastique à moyenne nulle
- **Challenge de l'identification** : gestion des perturbations inconnues
  - ◇ si  $v(t) = 0$ , alors pas de problème, juste un jeu algébrique pour trouver la relation entre  $y(t)$  et  $u(t)$
  - ◇ sinon l'identification fournit (généralement) un modèle du processus représenté par  $G_0$  mais également un modèle des perturbations  $v(t)$

# Méthodes avancées d'identification des systèmes

## Rappel

Avant de se lancer dans une méthode avancée (procédure complète), il est intéressant de connaître une approximation du système à étudier

→ Obtenir un modèle de comportement par les méthodes usuelles (Broïda, Second ordre...)

### Avantages :

- simples à mettre en œuvre
- rapides
- obtention d'un modèle de comportement simplifié, permettant l'initialisation d'algorithmes plus avancés

### Inconvénients :

- modèles simplistes (parfois trop)
- pas robustes aux perturbations (bruit sur les données, perturbations extérieures, ...)
- non prises en compte de toutes les données

**Solution : utiliser des méthodes avancées d'identification de systèmes.**

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

# Choix du signal d'excitation

## Principes

Pour identifier à partir des données, il est nécessaire que l'information soit contenue dans les données !

→ excitation dans tout le spectre de fréquence susceptible de contenir les constantes de temps du système

- $\sin(\omega t)$  : balayage en fréquence, parfait d'un point de vue spectre, mais pas toujours accepté par tous les systèmes
- $\delta(t)$  : parfait d'un point de vue théorique, difficile voire impossible à réaliser en pratique
- $b(t)$  : bruit blanc idéal d'un point de vue spectral mais réalisation pratique ?
- SBPA : signal binaire pseudo aléatoire : réalisation pratique d'un signal aléatoire (en anglais : Pseudo Random Binary Sequence, PRBS).
- parfois impossible d'exciter un système (systèmes environnementaux, machine en production par ex.) : utilisation des commandes naturelles du système comme signal d'entrée.



# Choix du signal d'excitation

## Principes

Pour identifier à partir des données, il est nécessaire que l'information soit contenue dans les données !

→ excitation dans tout le spectre de fréquence susceptible de contenir les constantes de temps du système

- $\sin(\omega t)$  : balayage en fréquence, parfait d'un point de vue spectre, mais pas toujours accepté par tous les systèmes
- $\delta(t)$  : parfait d'un point de vue théorique, difficile voire impossible à réaliser en pratique
- $b(t)$  : bruit blanc idéal d'un point de vue spectral mais réalisation pratique ?
- SBPA : signal binaire pseudo aléatoire : réalisation pratique d'un signal aléatoire (en anglais : Pseudo Random Binary Sequence, PRBS).
- parfois impossible d'exciter un système (systèmes environnementaux, machine en production par ex.) : utilisation des commandes naturelles du système comme signal d'entrée.

# Choix du signal d'excitation

## Principes

Pour identifier à partir des données, il est nécessaire que l'information soit contenue dans les données !

→ excitation dans tout le spectre de fréquence susceptible de contenir les constantes de temps du système

- $\sin(\omega t)$  : balayage en fréquence, parfait d'un point de vue spectre, mais pas toujours accepté par tous les systèmes
- $\delta(t)$  : parfait d'un point de vue théorique, difficile voire impossible à réaliser en pratique
- $b(t)$  : bruit blanc idéal d'un point de vue spectral mais réalisation pratique ?
- SBPA : signal binaire pseudo aléatoire : réalisation pratique d'un signal aléatoire (en anglais : Pseudo Random Binary Sequence, PRBS).
- parfois impossible d'exciter un système (systèmes environnementaux, machine en production par ex.) : utilisation des commandes naturelles du système comme signal d'entrée.

# Choix du signal d'excitation

## Principes

Pour identifier à partir des données, il est nécessaire que l'information soit contenue dans les données !

→ excitation dans tout le spectre de fréquence susceptible de contenir les constantes de temps du système

- $\sin(\omega t)$  : balayage en fréquence, parfait d'un point de vue spectre, mais pas toujours accepté par tous les systèmes
- $\delta(t)$  : parfait d'un point de vue théorique, difficile voire impossible à réaliser en pratique
- $b(t)$  : bruit blanc idéal d'un point de vue spectral mais réalisation pratique ?
- SBPA : signal binaire pseudo aléatoire : réalisation pratique d'un signal aléatoire (en anglais : Pseudo Random Binary Sequence, PRBS).
- parfois impossible d'exciter un système (systèmes environnementaux, machine en production par ex.) : utilisation des commandes naturelles du système comme signal d'entrée.

# Choix du signal d'excitation

## Principes


Pour identifier à partir des données, il est nécessaire que l'information soit contenue dans les données !

→ excitation dans tout le spectre de fréquence susceptible de contenir les constantes de temps du système

- $\sin(\omega t)$  : balayage en fréquence, parfait d'un point de vue spectre, mais pas toujours accepté par tous les systèmes
- $\delta(t)$  : parfait d'un point de vue théorique, difficile voire impossible à réaliser en pratique
- $b(t)$  : bruit blanc idéal d'un point de vue spectral mais réalisation pratique ?
- SBPA : signal binaire pseudo aléatoire : réalisation pratique d'un signal aléatoire (en anglais : Pseudo Random Binary Sequence, PRBS).
- parfois impossible d'exciter un système (systèmes environnementaux, machine en production par ex.) : utilisation des commandes naturelles du système comme signal d'entrée.

# Choix du signal d'excitation

## SBPA




- Séquence de  $N$  bits de **longueur** :  $L = 2^N - 1$
- $E[s(t)] = \frac{a}{L}$
- **Fonction d'autocorrélation**



# Choix du signal d'excitation

## SBPA




- Séquence de  $N$  bits de **longueur** :  $L = 2^N - 1$
- $E[s(t)] = \frac{a}{L}$
- **Fonction d'autocorrélation**



# Choix du signal d'excitation

## SBPA




- Séquence de  $N$  bits de **longueur** :  $L = 2^N - 1$
- $E[s(t)] = \frac{a}{L}$
- **Fonction d'autocorrélation**



# Choix du signal d'excitation

## SBPA

- **Spectre de la SBPA** (TF de la fonction d'autocorrélation)



- **Choix des paramètres d'une SBPA**

Plus la séquence est longue ( $L$ ) :

- ◇ plus il y a d'informations
- ◇ plus le transitoire est négligeable
- ◇ plus les organes "souffrent"
- ◇ plus les dérives s'accroissent

Deuxième compromis, plus  $a$  est petit :


- ◇ plus le signal est noyé dans le bruit
- ◇ moins les organes "souffrent"
- ◇ moins les dérives s'accroissent



# Choix du signal d'excitation

## SBPA

- **Spectre de la SBPA** (TF de la fonction d'autocorrélation)



- **Choix des paramètres d'une SBPA**

Plus la séquence est longue ( $L$ ) :

- ◇ plus il y a d'informations
- ◇ plus le transitoire est négligeable
- ◇ plus les organes "souffrent"
- ◇ plus les dérives s'accroissent

Deuxième compromis, plus  $a$  est petit :

- ◇ plus le signal est noyé dans le bruit
- ◇ moins les organes "souffrent"
- ◇ moins les dérives s'accroissent

# Choix du signal d'excitation

## SBPA

SBPA de longueur  $L = 2^N - 1$  envoyée à la fréquence  $1/T_e$  :

- plateau de longueur maximale :  $NT_e$
- plus petit plateau de longueur :  $T_e$

# Choix du signal d'excitation

## SBPA

SBPA de longueur  $L = 2^N - 1$  envoyée à la fréquence  $1/T_e$  :

- plateau de longueur maximale :  $NT_e$
- plus petit plateau de longueur :  $T_e$

Donc, **le choix de  $N$  (et donc  $L$ ) et de  $T_e$**  est un compromis entre :

- bonne identification du gain statique
- bonne excitation sur la bande de fréquence du système

# Choix du signal d'excitation

## SBPA

SBPA de longueur  $L = 2^N - 1$  envoyée à la fréquence  $1/T_e$  :

- plateau de longueur maximale :  $NT_e$
- plus petit plateau de longueur :  $T_e$

Donc, **le choix de  $N$  (et donc  $L$ ) et de  $T_e$**  est un compromis entre :


- bonne identification du gain statique
- bonne excitation sur la bande de fréquence du système

## Solution

- pour gain statique :  $NT_e = 3 \text{ à } 5 T_{MAX}$  ( $T_{MAX}$  = plus grande constante de temps du système)
- pour excitation :  $0.3 \frac{1}{T_e} = \frac{1}{2\pi T_{min}}$  ( $T_{min}$  = plus petite constante de temps du système)

# Choix du signal d'excitation

## SBPA



**Remarque :** Si  $T_{MAX} \gg T_{min}$ ,  $N$  devient vite très grand donc  $LT_e$  devient prohibitif!  
→ Identification de systèmes à constantes de temps éloignées complexe.

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- **Structure de modèle**
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

# Structure du modèle

## Modèles statiques et dynamiques

### Modèles statiques

- *dérivées* et *valeurs moyennes* non nulles
- composantes cycliques (périodiques)
- modèle du type
  - ◇  $y(t) = \varphi^T \theta + v(t)$   
où le vecteur de régression  $\varphi(t)$  est déterministe (parfaitement connu), ne dépend pas des valeurs passées de la sortie
  - ◇ *exemple* :  $y(t) = \varphi^T(t)\theta + v(t)$   
avec  $\varphi^T(t) = [1 \quad t \quad t^2]$

# Avant de commencer : les opérateurs

## Modèles à temps continu – Opérateur dérivée

- Signal à temps continu :  $y(t)$
- Transformée de Fourier :  $Y(\omega) = \int_{-\infty}^{\infty} y(t)e^{-i\omega t} dt$
- Transformée de Laplace :  $Y(s) = \int_{-\infty}^{\infty} y(t)e^{-st} dt$
- Système linéaire :

$$y(t) = g * u(t)$$

$$Y(\omega) = G(\omega)U(\omega)$$

$$Y(s) = G(s)U(s)$$

**Opérateur dérivée :**  $pu(t) = \dot{u}(t)$  fonctionne comme la variable de Laplace  $s$ , mais dans le domaine temporel.

**Exemple :** Équivalence des écritures suivantes

$$y(t) = 0.5\dot{u}(t) + u(t) \tag{1}$$

$$y(t) = (0.5p + 1)u(t) \tag{2}$$

$$Y(s) = (0.5s + 1)U(s) \tag{3}$$



# Avant de commencer : les opérateurs

## Modèles à temps discret – Opérateur retard

- Signal à temps discret :  $y(kh)$
- Transformée de Fourier :  $Y^{(h)}(\omega) = h \sum_{k=-\infty}^{\infty} y(kh) e^{-i\omega kh}$
- Transformée en  $z$  :  $Y(z) = \sum_{k=-\infty}^{\infty} y(kh) z^{-k}$
- Système linéaire :

$$y(kh) = g * u(kh)$$

$$Y^{(h)}(\omega) = G_d(e^{i\omega h}) U^{(h)}(\omega)$$

$$Y(z) = G_d(z) U(z)$$

**Opérateur retard** :  $qu(kh) = u(kh + h)$  fonctionne comme la variable  $z$ , mais dans le domaine temporel.

**Exemple** : Équivalence des écritures suivantes

$$y(kh) = 0.5u(kh) + u(kh - h) \quad (4)$$

$$y(kh) = (0.5 + q^{-1})u(kh) \quad (5)$$

$$Y(z) = (0.5 + z^{-1})U(z) \quad (6)$$

# Structure du modèle

## Modèles statiques et dynamiques

### Modèles dynamiques – Représentation polynomiale

- Forme générale pour un modèle à temps discret

$$y(t_k) = G(q^{-1})u(t_k) + H(q^{-1})e(t_k)$$

ou

$$y(t_k) = \varphi^T(t_k)\theta + v(t_k)$$

où le vecteur de régression  $\varphi(t_k)$  dépend des valeurs passées de  $y(t_k)$ ,  $u(t_k)$

- Structures classiques :
  - ◇ modèle ARX
  - ◇ modèle OE
  - ◇ modèle ARMAX
  - ◇ modèle BJ
- Ces modèles linéaires ne sont valables qu'autour d'un point de fonctionnement, avec une zone de variation assez étroite.

# Structure du modèle

## Modèle

### En pratique

- Les données expérimentales contiennent à la fois des composantes statiques et dynamiques

$$y(t_k) = \underbrace{y_s(t_k)}_{\text{composante statique}} + \underbrace{y_d(t_k)}_{\text{composante dynamique}} \quad (7)$$

- Approche habituelle
  - ◇ estimer la composante statique
  - ◇ enlever la composante statique avant d'estimer le modèle dynamique  
→ éliminer la composante moyenne des signaux d'E/S par exemple

# Structure du modèle

## Modèles paramétriques linéaires à temps discret

- *Fonction (opérateur) de transfert*

$$\underbrace{y(t_k) + a_1 y(t_{k-1}) + \dots + a_{n_a} y(t - n_a)}_{A(q^{-1})y(t_k)} = \underbrace{b_1 u(t_{k-1}) + \dots + b_{n_b} u(t - n_b)}_{B(q^{-1})u(t_k)}$$

$$A(q^{-1}) = 1 + a_1 q^{-1} + \dots + a_{n_a} q^{-n_a}$$

$$B(q^{-1}) = b_1 q^{-1} + \dots + b_{n_b} q^{-n_b}$$

$$q^{-1}u(t_k) = u(t_{k-1}) \quad \text{opérateur retard}$$

$$G(z) = \frac{Y(z)}{U(z)} = \frac{B(z)}{A(z)}, \quad z \text{ variable de la transformée en } Z$$

- *Représentation d'état*

$$\begin{cases} x(t_{k+1}) = Ax(t_k) + Bu(t_k) \\ y(t_k) = Cx(t_k) + Du(t_k) \end{cases}$$

$$G(z) = C(zI - A)^{-1}B + D$$

# Structure du modèle

## Modèles paramétriques linéaires à temps discret

- *Fonction (opérateur) de transfert*

$$\underbrace{y(t_k) + a_1 y(t_{k-1}) + \dots + a_{n_a} y(t - n_a)}_{A(q^{-1})y(t_k)} = \underbrace{b_1 u(t_{k-1}) + \dots + b_{n_b} u(t - n_b)}_{B(q^{-1})u(t_k)}$$

$$A(q^{-1}) = 1 + a_1 q^{-1} + \dots + a_{n_a} q^{-n_a}$$

$$B(q^{-1}) = b_1 q^{-1} + \dots + b_{n_b} q^{-n_b}$$

$$q^{-1}u(t_k) = u(t_{k-1}) \quad \text{opérateur retard}$$

$$G(z) = \frac{Y(z)}{U(z)} = \frac{B(z)}{A(z)}, \quad z \text{ variable de la transformée en } Z$$

- *Représentation d'état*

$$\begin{cases} x(t_{k+1}) = Ax(t_k) + Bu(t_k) \\ y(t_k) = Cx(t_k) + Du(t_k) \end{cases}$$

$$G(z) = C(zI - A)^{-1}B + D$$

# Structure du modèle

## Modèles paramétriques linéaires à temps continu

- *Fonction (opérateur) de transfert*

$$\underbrace{\frac{d^n y(t)}{dt^n} + a_1 \frac{d^{n-1} y(t)}{dt^{n-1}} + \dots + a_n y(t)}_{A(p)y(t)} = \underbrace{b_0 \frac{d^m u(t)}{dt^m} + \dots + b_m u(t)}_{B(p)u(t)}$$

$$A(p) = p^n + a_1 p^{n-1} + \dots + a_n$$

$$B(p) = b_0 p^m + b_1 p^{m-1} + \dots + b_m$$

$$p = \frac{d}{dt} \quad \text{opérateur différentiel}$$

$$G(s) = \frac{Y(s)}{U(s)} = \frac{B(s)}{A(s)}, \quad s \text{ variable de Laplace}$$

- *Représentation d'état*

$$\begin{cases} \dot{x}(t) = Ax(t) + Bu(t) \\ y(t) = Cx(t) + Du(t) \end{cases}$$

$$G(s) = C(sI - A)^{-1}B + D$$

# Structure du modèle

## Modèles paramétriques linéaires à temps continu

- *Fonction (opérateur) de transfert*

$$\underbrace{\frac{d^n y(t)}{dt^n} + a_1 \frac{d^{n-1} y(t)}{dt^{n-1}} + \dots + a_n y(t)}_{A(p)y(t)} = \underbrace{b_0 \frac{d^m u(t)}{dt^m} + \dots + b_m u(t)}_{B(p)u(t)}$$

$$A(p) = p^n + a_1 p^{n-1} + \dots + a_n$$

$$B(p) = b_0 p^m + b_1 p^{m-1} + \dots + b_m$$

$$p = \frac{d}{dt} \quad \text{opérateur différentiel}$$

$$G(s) = \frac{Y(s)}{U(s)} = \frac{B(s)}{A(s)}, \quad s \text{ variable de Laplace}$$

- *Représentation d'état*

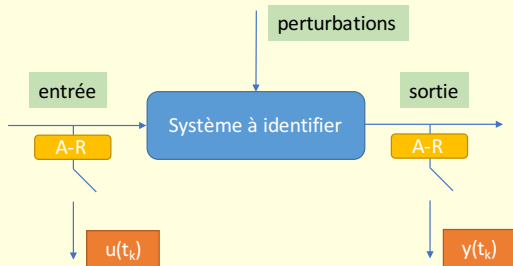
$$\begin{cases} \dot{x}(t) = Ax(t) + Bu(t) \\ y(t) = Cx(t) + Du(t) \end{cases}$$

$$G(s) = C(sI - A)^{-1}B + D$$

# Structure du modèle

## Choix

**Objectif :** déterminer un modèle paramétrique à temps discret d'un système à partir de la mesure des signaux d'E/S



Une fois les signaux acquis, plusieurs choix doivent encore être effectués :


- quel modèle pour représenter l'effet des perturbations (bruits) ?
- quelle structure de modèles pour le système ?
- quelle méthode d'estimation des paramètres du modèle choisi ?



# Structure du modèle

## Perturbations

- bruit sur la sortie, entrée non mesurée, bruit de capteur,...
- souvent représentées comme des processus stochastiques stationnaires prenant la forme d'un terme additif sur la sortie



$$v(t_k) = H_0(q^{-1})e(t_k)$$


$$y(t_k) = G_0(q^{-1})u(t_k) + H_0(q^{-1})e(t_k)$$

- Hypothèse de travail :  $e(t_k)$  est un **bruit blanc gaussien** à temps discret
- **Densité de probabilité** définie par ses 2 premiers moments (moyenne et variance)
- $e(t_k) \in \mathcal{N}(0, \lambda^2)$

# Structure du modèle

## Modèles dynamiques – Représentation polynomiale

Modèles dépendant de l'hypothèse sur les perturbations





$$A(q^{-1})y(t_k) = B(q^{-1})u(t_k) + e(t_k)$$

# Structure du modèle

## Modèles dynamiques – Représentation polynomiale


Modèles dépendant de l'hypothèse sur les perturbations




# Structure du modèle

## Modèles dynamiques – Représentation polynomiale

Modèles dépendant de l'hypothèse sur les perturbations




$$A(q^{-1})y(t_k) = B(q^{-1})u(t_k) + e(t_k)$$



$$A(q^{-1})y(t_k) = B(q^{-1})u(t_k) + C(q^{-1})e(t_k)$$

**OE**




$$y(t_k) = \frac{B(q^{-1})}{F(q^{-1})}u(t_k) + e(t_k)$$


# Structure du modèle

## Modèles dynamiques – Représentation polynomiale


Modèles dépendant de l'hypothèse sur les perturbations




$$A(q^{-1})y(t_k) = B(q^{-1})u(t_k) + e(t_k)$$



$$A(q^{-1})y(t_k) = B(q^{-1})u(t_k) + C(q^{-1})e(t_k)$$




$$y(t_k) = \frac{B(q^{-1})}{F(q^{-1})}u(t_k) + e(t_k)$$



$$y(t_k) = \frac{B(q^{-1})}{F(q^{-1})}u(t_k) + \frac{C(q^{-1})}{D(q^{-1})}e(t_k)$$


# Structure du modèle

## Paramétrisation



Système vrai  $\mathcal{S}$

$$y(t_k) = G_0(q^{-1})u(t_k) + H_0(q^{-1})e(t_k)$$



Modèle estimé  $\mathcal{M}$

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H_0(q^{-1}, \theta)e(t_k)$$

- Le vecteur des paramètres  $\theta$  rassemble les coeff de  $G(q^{-1}, \theta)$  et  $H(q^{-1}, \theta)$   
**L'estimée de  $\theta$  sera notée  $\hat{\theta}$**  et dépendra de l'estimateur utilisé (MC, ...).
- But de l'estimation : fournir le vecteur de paramètres le plus approprié en fonction du but recherché
- Ce cours : modèle de type fonction de transfert

# Structure du modèle

## Paramétrisation

### Paramétrisation des fonctions de transfert

- Paramétrisation des fonctions de transfert  $G(q^{-1}, \theta)$  et  $H(q^{-1}, \theta)$   
(paramétrisation utilisée au sein de la boîte à outils SID de Matlab)

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1})}{F(q^{-1})} = q^{-n_k} \frac{b_0 + b_1(q^{-1}) + \dots + b_{n_b-1} q^{-n_b+1}}{1 + f_1(q^{-1}) + \dots + f_{n_f} q^{-n_f}}$$

$$H(q^{-1}, \theta) = \frac{C(q^{-1})}{D(q^{-1})} = q^{-n_k} \frac{1 + c_1(q^{-1}) + \dots + c_{n_c} q^{-n_c}}{1 + d_1(q^{-1}) + \dots + d_{n_d} q^{-n_d}}$$

- Le vecteur des paramètres  $\theta$  rassemble les coefficients  $b_i, f_i, c_i, d_i$
- $n_k$  représente le retard (nombre d'échantillons de retard) entre la sortie et l'entrée
- $n_f, n_b, n_c$  et  $n_d$  correspondent au nombre de paramètres à estimer des polynômes

# Structure du modèle

## Paramétrisation

### Paramétrisation des fonctions de transfert

- Paramétrisation des fonctions de transfert  $G(q^{-1}, \theta)$  et  $H(q^{-1}, \theta)$   
(paramétrisation utilisée au sein de la boîte à outils SID de Matlab)

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1})}{F(q^{-1})} = q^{-n_k} \frac{b_0 + b_1(q^{-1}) + \dots + b_{n_b-1} q^{-n_b+1}}{1 + f_1(q^{-1}) + \dots + f_{n_f} q^{-n_f}}$$

$$H(q^{-1}, \theta) = \frac{C(q^{-1})}{D(q^{-1})} = q^{-n_k} \frac{1 + c_1(q^{-1}) + \dots + c_{n_c} q^{-n_c}}{1 + d_1(q^{-1}) + \dots + d_{n_d} q^{-n_d}}$$

- Le vecteur des paramètres  $\theta$  rassemble les coefficients  $b_i, f_i, c_i, d_i$
- $n_k$  représente le retard (nombre d'échantillons de retard) entre la sortie et l'entrée
- $n_f, n_b, n_c$  et  $n_d$  correspondent au nombre de paramètres à estimer des polynômes



# Structure du modèle

## Paramétrisation

### Paramétrisation des fonctions de transfert

- Paramétrisation des fonctions de transfert  $G(q^{-1}, \theta)$  et  $H(q^{-1}, \theta)$   
(paramétrisation utilisée au sein de la boîte à outils SID de Matlab)

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1})}{F(q^{-1})} = q^{-n_k} \frac{b_0 + b_1(q^{-1}) + \dots + b_{n_b-1} q^{-n_b+1}}{1 + f_1(q^{-1}) + \dots + f_{n_f} q^{-n_f}}$$

$$H(q^{-1}, \theta) = \frac{C(q^{-1})}{D(q^{-1})} = q^{-n_k} \frac{1 + c_1(q^{-1}) + \dots + c_{n_c} q^{-n_c}}{1 + d_1(q^{-1}) + \dots + d_{n_d} q^{-n_d}}$$

- Le vecteur des paramètres  $\theta$  rassemble les coefficients  $b_i, f_i, c_i, d_i$
- $n_k$  représente le retard (nombre d'échantillons de retard) entre la sortie et l'entrée
- $n_f, n_b, n_c$  et  $n_d$  correspondent au nombre de paramètres à estimer des polynômes

# Structure du modèle

## Paramétrisation

### Paramétrisation des fonctions de transfert

- Paramétrisation des fonctions de transfert  $G(q^{-1}, \theta)$  et  $H(q^{-1}, \theta)$   
(paramétrisation utilisée au sein de la boîte à outils SID de Matlab)

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1})}{F(q^{-1})} = q^{-n_k} \frac{b_0 + b_1(q^{-1}) + \dots + b_{n_b-1} q^{-n_b+1}}{1 + f_1(q^{-1}) + \dots + f_{n_f} q^{-n_f}}$$

$$H(q^{-1}, \theta) = \frac{C(q^{-1})}{D(q^{-1})} = q^{-n_k} \frac{1 + c_1(q^{-1}) + \dots + c_{n_c} q^{-n_c}}{1 + d_1(q^{-1}) + \dots + d_{n_d} q^{-n_d}}$$

- Le vecteur des paramètres  $\theta$  rassemble les coefficients  $b_i, f_i, c_i, d_i$
- $n_k$  représente le retard (nombre d'échantillons de retard) entre la sortie et l'entrée
- $n_f, n_b, n_c$  et  $n_d$  correspondent au nombre de paramètres à estimer des polynômes

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- **Méthodes d'estimation paramétrique**
- Cas d'un modèle OE


4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan


# Méthodes d'estimation

## Deux grandes méthodes

- Minimisation de l'erreur de sortie




- Minimisation de l'erreur de prédiction



# Méthodes d'estimation


## Erreur de prédiction



- Pour un vecteur de paramètres donné  $\theta$ , le modèle permet de calculer la prédiction de la sortie notée  $\hat{y}(t_k, \theta)$ .
- Il faut alors déterminer  $\theta$  tel que  $\hat{y}(t_k, \theta)$  soit “la plus proche possible” de  $y(t_k)$

# Méthodes d'estimation


## Erreur de prédiction



- Pour un vecteur de paramètres donné  $\theta$ , le modèle permet de calculer la prédiction de la sortie notée  $\hat{y}(t_k, \theta)$ .
- Il faut alors déterminer  $\theta$  tel que  $\hat{y}(t_k, \theta)$  soit “la plus proche possible” de  $y(t_k)$

# Méthodes d'estimation

## Erreur de prédiction




Pour résoudre ce problème d'estimation, il faut remarquer :

- 1 la prédiction de la sortie  $\hat{y}(t_k, \theta)$  dépend de la structure de modèle choisie et donc du modèle de bruit
- 2 le concept "doit être la plus proche possible" doit être formulé mathématiquement

# Méthodes d'estimation

## Erreur de prédiction




Pour résoudre ce problème d'estimation, il faut remarquer :

- 1 la prédiction de la sortie  $\hat{y}(t_k, \theta)$  dépend de la structure de modèle choisie et donc du modèle de bruit
- 2 le concept "doit être la plus proche possible" doit être formulé mathématiquement



# Méthodes d'estimation

## Erreur de prédiction



Pour résoudre ce problème d'estimation, il faut remarquer :

- ❶ la prédiction de la sortie  $\hat{y}(t_k, \theta)$  dépend de la structure de modèle choisie et donc du modèle de bruit
- ❷ le concept “doit être la plus proche possible” doit être formulé mathématiquement

# Méthodes d'estimation

## Erreur de prédiction – Cas général

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_k$

$$\hat{y}(t_k, \theta)$$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta)$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \hat{y}(t_k, \theta))^2$$

- 4 Les paramètres optimaux sont ceux qui minimisent la fonction de coût

$$\hat{\theta} = \arg \min_{\theta} V(\theta, Z^N)$$

# Méthodes d'estimation

## Erreur de prédiction – Cas général

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

❶ Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_k$   
 $\hat{y}(t_k, \theta)$

❷ Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta)$

❸ Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \hat{y}(t_k, \theta))^2$$

❹ Les paramètres optimaux sont ceux qui minimisent la fonction de coût  
 $\hat{\theta} = \arg \min_{\theta} V(\theta, Z^N)$

# Méthodes d'estimation

## Erreur de prédiction – Cas général

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_k$   
 $\hat{y}(t_k, \theta)$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta)$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \hat{y}(t_k, \theta))^2$$

- 4 Les paramètres optimaux sont ceux qui minimisent la fonction de coût  
 $\hat{\theta} = \arg \min_{\theta} V(\theta, Z^N)$

# Méthodes d'estimation

## Erreur de prédiction – Cas général

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_k$   
 $\hat{y}(t_k, \theta)$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta)$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \hat{y}(t_k, \theta))^2$$

- 4 Les paramètres optimaux sont ceux qui minimisent la fonction de coût  
 $\hat{\theta} = \arg \min_{\theta} V(\theta, Z^N)$

# Méthodes d'estimation

## Erreur de prédiction – Cas général

- Soit le modèle général :

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H(q^{-1}, \theta)e(t_k)$$

- Multiplions par  $H^{-1}(q^{-1}, \theta)$  (pour “blanchir” le terme de bruit)

$$H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) - y(t_k) + H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

- Puisque  $e(t_k)$  est un bruit blanc, on en déduit la meilleure prédiction (cas général) :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Suivant les modèles de bruit et du système cette équation prend plusieurs formes différentes.

Cas le plus simple (linéaire en les paramètres) : **modèle ARX**.

# Méthodes d'estimation

## Erreur de prédiction – Cas général

- Soit le modèle général :

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H(q^{-1}, \theta)e(t_k)$$

- Multiplions par  $H^{-1}(q^{-1}, \theta)$  (pour “blanchir” le terme de bruit)

$$H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) - y(t_k) + H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

- Puisque  $e(t_k)$  est un bruit blanc, on en déduit la meilleure prédiction (cas général) :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Suivant les modèles de bruit et du système cette équation prend plusieurs formes différentes.

Cas le plus simple (linéaire en les paramètres) : **modèle ARX**.

# Méthodes d'estimation

## Erreur de prédiction – Cas général

- Soit le modèle général :

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H(q^{-1}, \theta)e(t_k)$$

- Multiplions par  $H^{-1}(q^{-1}, \theta)$  (pour “blanchir” le terme de bruit)

$$H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) - y(t_k) + H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

- Puisque  $e(t_k)$  est un bruit blanc, on en déduit la meilleure prédiction (cas général) :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Suivant les modèles de bruit et du système cette équation prend plusieurs formes différentes.

Cas le plus simple (linéaire en les paramètres) : **modèle ARX**.



# Méthodes d'estimation

## Erreur de prédiction – Cas général

- Soit le modèle général :

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H(q^{-1}, \theta)e(t_k)$$

- Multiplions par  $H^{-1}(q^{-1}, \theta)$  (pour “blanchir” le terme de bruit)

$$H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) - y(t_k) + H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

- Puisque  $e(t_k)$  est un bruit blanc, on en déduit la meilleure prédiction (cas général) :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Suivant les modèles de bruit et du système cette équation prend plusieurs formes différentes.

Cas le plus simple (linéaire en les paramètres) : **modèle ARX**.

## Erreur de prédiction – Cas général

- Soit le modèle général :

$$y(t_k) = G(q^{-1}, \theta)u(t_k) + H(q^{-1}, \theta)e(t_k)$$

- Multiplions par  $H^{-1}(q^{-1}, \theta)$  (pour “blanchir” le terme de bruit)

$$H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) - y(t_k) + H^{-1}(q^{-1}, \theta)y(t_k) = H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

$$y(t_k) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k) + e(t_k)$$

- Puisque  $e(t_k)$  est un bruit blanc, on en déduit la meilleure prédiction (cas général) :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Suivant les modèles de bruit et du système cette équation prend plusieurs formes différentes.

Cas le plus simple (linéaire en les paramètres) : **modèle ARX**.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \dots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \quad \dots \quad -y(t_{k-n_a}) \quad u(t_{k-n_k}) \quad \dots \quad u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \quad \dots \quad a_{n_a} \quad b_0 \quad \dots \quad b_{n_b-1}]$$

- Prédiction de la sortie = fonction linéaire en les paramètres, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \dots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \dots -y(t_{k-n_a}) \ u(t_{k-n_k}) \dots u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \dots a_{n_a} \ b_0 \dots b_{n_b-1}]$$

- Prédiction de la sortie = fonction linéaire en les paramètres, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \cdots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \cdots -y(t_{k-n_a}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \cdots a_{n_a} \quad b_0 \cdots b_{n_b-1}]$$

- Prédiction de la sortie = fonction linéaire en les paramètres, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \cdots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \cdots -y(t_{k-n_a}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \cdots a_{n_a} \quad b_0 \cdots b_{n_b-1}]$$

- Prédiction de la sortie = fonction linéaire en les paramètres, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \cdots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \cdots -y(t_{k-n_a}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \cdots a_{n_a} \quad b_0 \cdots b_{n_b-1}]$$

- Prédiction de la sortie = **fonction linéaire en les paramètres**, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.

## Erreur de prédiction – Cas d'un modèle ARX

- Soit le modèle ARX

$$y(t_k) = q^{n_k} \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k) + \frac{1}{A(q^{-1}, \theta)} e(t_k) \quad (8)$$

- **Prédiction de la sortie**

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = (1 - A(q^{-1}, \theta))y(t_k) + q^{-n_k} B(q^{-1}, \theta)u(t_k)$$

$$\hat{y}(t_k, \theta) = -a_1 y(t_{k-1}) - a_{n_a} y(t_{k-n_a}) + b_0 u(t_{k-n_k}) + \dots + b_{n_b-1} u(t_{k-n_k-n_b+1})$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

$$\varphi^T(t_k) = [-y(t_{k-1}) \ \dots \ -y(t_{k-n_a}) \ u(t_{k-n_k}) \ \dots \ u(t_{k-n_k-n_b+1})]$$

$$\theta = [a_1 \ \dots \ a_{n_a} \ b_0 \ \dots \ b_{n_b-1}]$$

- Prédiction de la sortie = **fonction linéaire en les paramètres**, le problème est donc celui d'une régression linéaire et les paramètres peuvent être cherchés par des procédures de moindres carrés.



# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_{k-1}$  (*modèle de régression linéaire*)  $\hat{y}(t_k, \theta) = \varphi^T(t_k)\theta$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta) = y(t_k) - \varphi^T(t_k)\theta$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \varphi^T(t_k)\theta)^2$$

- 4 Ce critère est une fonction quadratique de  $\theta$ . Donc au minimum du critère, sa dérivée première par rapport à  $\theta$  est nulle.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_{k-1}$  (*modèle de régression linéaire*)  $\hat{y}(t_k, \theta) = \varphi^T(t_k)\theta$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta) = y(t_k) - \varphi^T(t_k)\theta$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \varphi^T(t_k)\theta)^2$$

- 4 Ce critère est une fonction quadratique de  $\theta$ . Donc au minimum du critère, sa dérivée première par rapport à  $\theta$  est nulle.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_{k-1}$  (*modèle de régression linéaire*)  $\hat{y}(t_k, \theta) = \varphi^T(t_k)\theta$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta) = y(t_k) - \varphi^T(t_k)\theta$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \varphi^T(t_k)\theta)^2$$

- 4 Ce critère est une fonction quadratique de  $\theta$ . Donc au minimum du critère, sa dérivée première par rapport à  $\theta$  est nulle.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX

Soit un ensemble  $Z^N$  de données d'E/S

$$Z^N = \{u(t_1), y(t_1), u(t_2), y(t_2), \dots, u(t_N), y(t_N)\}$$

- 1 Calculer la prédiction de la sortie à partir des données jusqu'à l'instant  $t_{k-1}$  (*modèle de régression linéaire*)  $\hat{y}(t_k, \theta) = \varphi^T(t_k)\theta$

- 2 Former l'erreur de prédiction  $\varepsilon(t_k) = y(t_k) - \hat{y}(t_k, \theta) = y(t_k) - \varphi^T(t_k)\theta$

- 3 Construire la fonction de coût (ou critère)

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \sum_{k=1}^N (y(t_k) - \varphi^T(t_k)\theta)^2$$

- 4 Ce critère est une fonction quadratique de  $\theta$ . Donc au minimum du critère, sa dérivée première par rapport à  $\theta$  est nulle.

## Erreur de prédiction – Cas d'un modèle ARX

### 5 Calcul de la dérivée

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = \frac{2}{N} \sum_{k=1}^N \varphi(t_k)(y(t_k) - \varphi^T(t_k)\theta) = 0$$

$$\frac{2}{N} \sum_{k=1}^N (\varphi(t_k)y(t_k) - \varphi(t_k)\varphi^T(t_k)\theta) = 0$$

### 6 Déduction : estimateur des moindres carrés

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k)\varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k)y(t_k)$$

à condition que l'inverse existe.

## Erreur de prédiction – Cas d'un modèle ARX

- 5 Calcul de la dérivée

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = \frac{2}{N} \sum_{k=1}^N \varphi(t_k)(y(t_k) - \varphi^T(t_k)\theta) = 0$$

$$\frac{2}{N} \sum_{k=1}^N (\varphi(t_k)y(t_k) - \varphi(t_k)\varphi^T(t_k)\theta) = 0$$

- 6 Dédution : estimateur des moindres carrés

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k)\varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k)y(t_k)$$

à condition que l'inverse existe.

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX, formulation matricielle

- La forme matricielle est plus facilement utilisée. L'erreur de prédiction (ou résidus) s'écrit

$$\begin{bmatrix} \varepsilon(t_1) \\ \vdots \\ \varepsilon(t_N) \end{bmatrix} = \begin{bmatrix} y(t_1) \\ \vdots \\ y(t_N) \end{bmatrix} - \begin{bmatrix} \varphi^T(t_1) \\ \vdots \\ \varphi^T(t_N) \end{bmatrix} \theta$$
$$\varepsilon(t_k) = Y_N - \Phi_N \theta$$

- Le critère s'écrit :

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \varepsilon_N^T \varepsilon_N = \frac{1}{N} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

- La condition de gradient nul conduit à :

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = -\Phi_N^T Y_N + \theta^T (\Phi_N^T \Phi_N) = 0$$

- Déduction de l'estimateur de moindres carrés sous forme matricielle

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX, formulation matricielle

- La forme matricielle est plus facilement utilisée. L'erreur de prédiction (ou résidus) s'écrit

$$\begin{bmatrix} \varepsilon(t_1) \\ \vdots \\ \varepsilon(t_N) \end{bmatrix} = \begin{bmatrix} y(t_1) \\ \vdots \\ y(t_N) \end{bmatrix} - \begin{bmatrix} \varphi^T(t_1) \\ \vdots \\ \varphi^T(t_N) \end{bmatrix} \theta$$
$$\varepsilon(t_k) = Y_N - \Phi_N \theta$$

- Le critère s'écrit :

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \varepsilon_N^T \varepsilon_N = \frac{1}{N} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

- La condition de gradient nul conduit à :

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = -\Phi_N^T Y_N + \theta^T (\Phi_N^T \Phi_N) = 0$$

- Déduction de l'estimateur de moindres carrés sous forme matricielle

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$



# Méthodes d'estimation

## Erreur de prédiction – Cas d'un modèle ARX, formulation matricielle

- La forme matricielle est plus facilement utilisée. L'erreur de prédiction (ou résidus) s'écrit

$$\begin{bmatrix} \varepsilon(t_1) \\ \vdots \\ \varepsilon(t_N) \end{bmatrix} = \begin{bmatrix} y(t_1) \\ \vdots \\ y(t_N) \end{bmatrix} - \begin{bmatrix} \varphi^T(t_1) \\ \vdots \\ \varphi^T(t_N) \end{bmatrix} \theta$$
$$\varepsilon(t_k) = Y_N - \Phi_N \theta$$

- Le critère s'écrit :

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \varepsilon_N^T \varepsilon_N = \frac{1}{N} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

- La condition de gradient nul conduit à :

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = -\Phi_N^T Y_N + \theta^T (\Phi_N^T \Phi_N) = 0$$

- Déduction de l'estimateur de moindres carrés sous forme matricielle

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

## Erreur de prédiction – Cas d'un modèle ARX, formulation matricielle

- La forme matricielle est plus facilement utilisée. L'erreur de prédiction (ou résidus) s'écrit

$$\begin{bmatrix} \varepsilon(t_1) \\ \vdots \\ \varepsilon(t_N) \end{bmatrix} = \begin{bmatrix} y(t_1) \\ \vdots \\ y(t_N) \end{bmatrix} - \begin{bmatrix} \varphi^T(t_1) \\ \vdots \\ \varphi^T(t_N) \end{bmatrix} \theta$$
$$\varepsilon(t_k) = Y_N - \Phi_N \theta$$

- Le critère s'écrit :

$$V(\theta, Z^N) = \frac{1}{N} \sum_{k=1}^N \varepsilon^2(t_k) = \frac{1}{N} \varepsilon_N^T \varepsilon_N = \frac{1}{N} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

- La condition de gradient nul conduit à :

$$\frac{\partial V(\theta, Z^N)}{\partial \theta} = -\Phi_N^T Y_N + \theta^T (\Phi_N^T \Phi_N) = 0$$

- Déduction de l'estimateur de moindres carrés sous forme matricielle

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

## Erreur de prédiction – Cas d'un modèle ARX, aspects numériques

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

### Remarque sur l'implantation numérique :

- Il est fortement *déconseillé* d'implémenter ces formules directement, l'inversion de la matrice  $(\Phi_N^T \Phi_N)$  entraîne des erreurs numériques (dues à un mauvais conditionnement).
- *Alternatives* à l'inversion de matrice :
  - ◇ décomposition en valeurs singulières (SVD)
  - ◇ décomposition QR→ mieux adaptées pour les problèmes mal conditionnés (cad où la matrice à inverse est numériquement mal conditionnée)
- Sous Matlab : `pinv` ou

$$\hat{\theta}_{mc} = \Phi_N \backslash Y_N$$

## Erreur de prédiction – Cas d'un modèle ARX, aspects numériques

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

### Remarque sur l'implantation numérique :

- Il est fortement *déconseillé* d'implémenter ces formules directement, l'inversion de la matrice  $(\Phi_N^T \Phi_N)$  entraîne des erreurs numériques (dues à un mauvais conditionnement).
- *Alternatives* à l'inversion de matrice :
  - ◇ décomposition en valeurs singulières (SVD)
  - ◇ décomposition QR→ mieux adaptées pour les problèmes mal conditionnés (cad où la matrice à inverse est numériquement mal conditionnée)
- Sous Matlab : `pinv` ou

$$\hat{\theta}_{mc} = \Phi_N \backslash Y_N$$

## Erreur de prédiction – Cas d'un modèle ARX, aspects numériques

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

### Remarque sur l'implantation numérique :

- Il est fortement *déconseillé* d'implémenter ces formules directement, l'inversion de la matrice  $(\Phi_N^T \Phi_N)$  entraîne des erreurs numériques (dues à un mauvais conditionnement).
- *Alternatives* à l'inversion de matrice :
  - ◊ décomposition en valeurs singulières (SVD)
  - ◊ décomposition QR
  - mieux adaptées pour les problèmes mal conditionnés (cad où la matrice à inverse est numériquement mal conditionnée)
- Sous Matlab : pinv ou

$$\hat{\theta}_{mc} = \Phi_N \backslash Y_N$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$



## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- On cherche à identifier un **système du premier ordre** représenté par :

$$G(q^{-1}, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

- Hypothèse** : structure de modèle de type ARX

$$y(t_k, \theta) = \frac{B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(t_k, \theta) + \frac{1}{A(q^{-1}, \theta)} e(t_k, \theta)$$

$$y(t_k, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} u(t_k, \theta) + \frac{1}{1 + a_1 q^{-1}} e(t_k, \theta)$$

$$(1 + a_1 q^{-1})y(t_k, \theta) = b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 q^{-1} y(t_k, \theta) + b_1 q^{-1} u(t_k, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = -a_1 y(t_{k-1}, \theta) + b_1 u(t_{k-1}, \theta) + e(t_k, \theta)$$

$$y(t_k, \theta) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)] \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + e(t_k, \theta)$$

$$y(t_k, \theta) = \varphi^T(t_k) \theta + e(t_k, \theta)$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- Régression linéaire en les paramètres :

$$y(t_k, \theta) = \varphi^T(t_k)\theta + e(t_k, \theta)$$

$$\text{avec : } \varphi^T(t_k) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)]$$

$$\text{et : } \theta = \begin{pmatrix} a_1 \\ b_1 \end{pmatrix}$$

Pour  $N$  données ( $k = 1$  à  $N$ ), on obtient l'écriture matricielle suivante :

$$\begin{bmatrix} y(t_2) \\ \vdots \\ y(t_N) \end{bmatrix} = \begin{bmatrix} -y(t_1) & u(t_1) \\ \vdots & \vdots \\ -y(t_{N-1}) & u(t_{N-1}) \end{bmatrix} \theta + \begin{bmatrix} e(t_2) \\ \vdots \\ e(t_N) \end{bmatrix}$$

- On en déduit :

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- Régression linéaire en les paramètres :

$$y(t_k, \theta) = \varphi^T(t_k)\theta + e(t_k, \theta)$$

$$\text{avec : } \varphi^T(t_k) = [-y(t_{k-1}, \theta) \quad u(t_{k-1}, \theta)]$$

$$\text{et : } \theta = \begin{pmatrix} a_1 \\ b_1 \end{pmatrix}$$

Pour  $N$  données ( $k = 1$  à  $N$ ), on obtient l'écriture matricielle suivante :

$$\begin{bmatrix} y(t_2) \\ \vdots \\ y(t_N) \end{bmatrix} = \begin{bmatrix} -y(t_1) & u(t_1) \\ \vdots & \vdots \\ -y(t_{N-1}) & u(t_{N-1}) \end{bmatrix} \theta + \begin{bmatrix} e(t_2) \\ \vdots \\ e(t_N) \end{bmatrix}$$

- On en déduit :

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

# Méthodes d'estimation

## Exemple – Estimation d'un modèle ARX d'ordre 1

- Remarque : sous Matlab l'expression

$$\begin{bmatrix} y(t_2) \\ \vdots \\ y(t_N) \end{bmatrix} = \begin{bmatrix} -y(t_1) & u(t_1) \\ \vdots & \vdots \\ -y(t_{N-1}) & u(t_{N-1}) \end{bmatrix} \theta + \begin{bmatrix} e(t_2) \\ \vdots \\ e(t_N) \end{bmatrix}$$

$$\hat{\theta}_{mc} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

se code :

```
Phi = [-y(1:N-1) u(1:N-1)];
```

```
Y = y(2:N);
```

```
theta = Phi \ Y
```

## Test d'un estimateur

Comment tester le bon fonctionnement d'un estimateur sous Matlab ?

- Etape 1 : tester l'estimateur sous un exemple académique
- Etape 2 : si le test est concluant, alors utilisation de l'estimateur sur des données réelles

Etapes à suivre pour le test d'un estimateur sur un exemple

- ① choix d'un système "vrai" à identifier, par exemple :  $G(q^{-1}, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$
- ② choix d'une structure de modèle, par exemple ARX
- ③ choix du signal d'excitation, par exemple SBPA ou bruit blanc

→ On obtient alors un jeu de données d'E/S  $[y(t) \ u(t)]$  sur lequel tester l'estimateur :

- ④ former  $u(t)$ , simuler le système "vrai" pour obtenir  $y(t)$ , ajouter du bruit  $e(t)$
- ⑤ représenter les données à l'écran pour vérification visuelle
- ⑥ former les matrices  $\Phi_N$  et  $Y_N$
- ⑦ calculer  $\hat{\theta}_{mc}$
- ⑧ comparer aux paramètres du modèle "vrai" pour validation.



## Test d'un estimateur

Comment tester le bon fonctionnement d'un estimateur sous Matlab ?

- Etape 1 : tester l'estimateur sous un exemple académique
- Etape 2 : si le test est concluant, alors utilisation de l'estimateur sur des données réelles

Etapes à suivre pour le test d'un estimateur sur un exemple

- ① choix d'un système "vrai" à identifier, par exemple :  $G(q^{-1}, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$
- ② choix d'une structure de modèle, par exemple ARX
- ③ choix du signal d'excitation, par exemple SBPA ou bruit blanc

→ On obtient alors un jeu de données d'E/S  $[y(t) \ u(t)]$  sur lequel tester l'estimateur :

- ④ former  $u(t)$ , simuler le système "vrai" pour obtenir  $y(t)$ , ajouter du bruit  $e(t)$
- ⑤ représenter les données à l'écran pour vérification visuelle
- ⑥ former les matrices  $\Phi_N$  et  $Y_N$
- ⑦ calculer  $\hat{\theta}_{mc}$
- ⑧ comparer aux paramètres du modèle "vrai" pour validation.

## Test d'un estimateur

Comment tester le bon fonctionnement d'un estimateur sous Matlab ?

- Etape 1 : tester l'estimateur sous un exemple académique
- Etape 2 : si le test est concluant, alors utilisation de l'estimateur sur des données réelles

Etapes à suivre pour le test d'un estimateur sur un exemple

- ① choix d'un système "vrai" à identifier, par exemple :  $G(q^{-1}, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$
  - ② choix d'une structure de modèle, par exemple ARX
  - ③ choix du signal d'excitation, par exemple SBPA ou bruit blanc
- On obtient alors un jeu de données d'E/S  $[y(t) \ u(t)]$  sur lequel tester l'estimateur :
- ④ former  $u(t)$ , simuler le système "vrai" pour obtenir  $y(t)$ , ajouter du bruit  $e(t)$
  - ⑤ représenter les données à l'écran pour vérification visuelle
  - ⑥ former les matrices  $\Phi_N$  et  $Y_N$
  - ⑦ calculer  $\hat{\theta}_{mc}$
  - ⑧ comparer aux paramètres du modèle "vrai" pour validation.

## Test d'un estimateur

Pour aller [plus loin](#)

- Test de l'efficacité face au bruit :
  - ◇ ajouter du bruit en sortie sous une structure ARX et tester l'estimateur sur les données bruitées
- Test de l'efficacité face à une erreur de structure de modèle :
  - ◇ changer la structure du modèle "vrai" pour observer les performances de l'estimateur ARX face à un non-respect de l'hypothèse de structure
  - ◇ exemple : choisir une structure de modèle OE pour le modèle "vrai".

Exercice : créez vos données puis testez l'estimateur des moindres carrés sur l'exemple du 1er ordre suivant :

$$G(q^{-1}, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} = \frac{0.2 q^{-1}}{1 - 0.8 q^{-1}}$$

avec une structure ARX puis OE pour le système "vrai".

## Test d'un estimateur

Pour aller [plus loin](#)


- Test de l'efficacité face au bruit :
  - ◇ ajouter du bruit en sortie sous une structure ARX et tester l'estimateur sur les données bruitées
- Test de l'efficacité face à une erreur de structure de modèle :
  - ◇ changer la structure du modèle "vrai" pour observer les performances de l'estimateur ARX face à un non-respect de l'hypothèse de structure
  - ◇ exemple : choisir une structure de modèle OE pour le modèle "vrai".

**Exercice :** créez vos données puis testez l'estimateur des moindres carrés sur l'exemple du 1er ordre suivant :

$$G(q^{-1}, \theta) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}} = \frac{0.2 q^{-1}}{1 - 0.8 q^{-1}}$$

avec une structure ARX puis OE pour le système "vrai".

## Implémentation sous Matlab, exemple 1er ordre



% Simulation du système non bruité

B=[0 0.2];

A=[1 -0.8];

N=200;

S = idpoly(1,B,1,1,A);

u=sign(randn(N,1));

x=sim(S,u);

% Estimation des paramètres par MC

Phi=[-x(1:N-1) u(1:N-1)];

Y=ydet(2:N);

theta\_mc=(Phi\Y)'

ans -0.8000 0.2000

%y=B/Au

*% simulation de la **sortie non bruitée***

*% Matrice de régression*

*% Régresseur*

*% Estimation par MC*

*% On estime parfaitement bien les 2 paramètres*


*% Normal résolution d'un système sur-déterminé*

*% dans un contexte non bruité*


*% voir aussi la fonction **arx** de la SID*

*% datadet=iddata(x,u); idplot(datadet);*


*%Marx=arx(datadet,[1 1 1])*



## Implémentation sous Matlab, exemple 1er ordre



$$y(t_k) = \frac{B(q^{-1})}{A(q^{-1})} u(t_k) + e(t_k)$$



% Simulation du système bruité

```
randn('state',sum(100*clock));
```

```
e=0.2*randn(N,1);
```

```
y=sim(S,[u e]); % simulation de la sortie bruitée
```

```
dataS= iddata(y,u); % Objet de données iddata avec comme sortie et u comme entrée
```

```
idplot(dataS)
```

```
% Estimation des paramètres par MC
```

```
Phi=[-y(1:N-1) u(1:N-1)]; % Matrice de régression
```

```
Y=y(2:N); % Régresseur
```

```
theta_mc=(Phi\Y)'; % Estimation par MC
```

```
ans -0.4675 0.1898 % Les paramètres sont erronés
```

```
% voir aussi la fonction arx de la SID
```

```
% Marx=arx(dataS,[1 1 1])
```

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

## Prédicteur pour un modèle OE

- Cas général :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Structure de modèle OE :

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} \quad \text{et} \quad H(q^{-1}, \theta) = 1$$

- Prédicteur, cas OE :

$$\hat{y}(t_k, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} u(t_k)$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

Expression non linéaire en  $\theta$

avec :

$$\varphi^T(t_k) = [-\hat{y}(t_{k-1}) \cdots -\hat{y}(t_{k-n_f}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})] \quad (9)$$

$$\theta = (f_1 \cdots f_{n_f} \quad b_0 \cdots b_{n_b-1})^T \quad (10)$$



## Prédicteur pour un modèle OE

- Cas général :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Structure de modèle OE :

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} \quad \text{et} \quad H(q^{-1}, \theta) = 1$$

- Prédicteur, cas OE :

$$\hat{y}(t_k, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} u(t_k)$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

Expression non linéaire en  $\theta$

avec :

$$\varphi^T(t_k) = [-\hat{y}(t_{k-1}) \cdots -\hat{y}(t_{k-n_f}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})] \quad (9)$$

$$\theta = (f_1 \cdots f_{n_f} \quad b_0 \cdots b_{n_b-1})^T \quad (10)$$

## Prédicteur pour un modèle OE

- Cas général :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Structure de modèle OE :

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} \quad \text{et} \quad H(q^{-1}, \theta) = 1$$

- Prédicteur, cas OE :

$$\hat{y}(t_k, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} u(t_k)$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

Expression non linéaire en  $\theta$

avec :

$$\varphi^T(t_k) = [-\hat{y}(t_{k-1}) \cdots -\hat{y}(t_{k-n_f}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})] \quad (9)$$

$$\theta = (f_1 \cdots f_{n_f} \quad b_0 \cdots b_{n_b-1})^T \quad (10)$$

## Prédicteur pour un modèle OE

- Cas général :

$$\hat{y}(t_k, \theta) = (1 - H^{-1}(q^{-1}, \theta))y(t_k) + H^{-1}(q^{-1}, \theta)G(q^{-1}, \theta)u(t_k)$$

- Structure de modèle OE :

$$G(q^{-1}, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} \quad \text{et} \quad H(q^{-1}, \theta) = 1$$

- Prédicteur, cas OE :

$$\hat{y}(t_k, \theta) = q^{-n_k} \frac{B(q^{-1}, \theta)}{F(q^{-1}, \theta)} u(t_k)$$

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

Expression non linéaire en  $\theta$

avec :

$$\varphi^T(t_k) = [-\hat{y}(t_{k-1}) \cdots -\hat{y}(t_{k-n_f}) \quad u(t_{k-n_k}) \cdots u(t_{k-n_k-n_b+1})] \quad (9)$$

$$\theta = (f_1 \cdots f_{n_f} \quad b_0 \cdots b_{n_b-1})^T \quad (10)$$

## Prédicteur pour un modèle OE

- L'estimée  $\hat{\theta}$  est solution de :

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{N} \sum_{t=1}^N (y(t_k) - \varphi^T(t_k, \theta))^2}_{V(\theta, Z^N)}$$

- Difficulté : le minimum du critère est atteint lorsque la dérivée s'annule :

$$\left. \frac{\partial V_N(\theta, Z^N)}{\partial \theta} \right|_{\theta=\hat{\theta}} = 0$$

or la dérivée est une expression compliquée non linéaire en  $\theta$

$\implies$  Présence de plusieurs minima locaux (la dérivée s'annule pour plusieurs valeurs de  $\theta$ )

- Conséquence : la solution  $\hat{\theta}$  est calculée par des méthodes itératives (Gauss Newton, Gradient, ...)
- Problème majeur : estimer un **minimum local** (*initialisation très importante*)

## Prédicteur pour un modèle OE

- L'estimée  $\hat{\theta}$  est solution de :

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{N} \sum_{t=1}^N (y(t_k) - \varphi^T(t_k, \theta))^2}_{V(\theta, Z^N)}$$

- **Difficulté** : le minimum du critère est atteint lorsque la dérivée s'annule :

$$\left. \frac{\partial V_N(\theta, Z^N)}{\partial \theta} \right|_{\theta=\hat{\theta}} = 0$$

or la dérivée est une expression compliquée non linéaire en  $\theta$

$\implies$  Présence de plusieurs minima locaux (la dérivée s'annule pour plusieurs valeurs de  $\theta$ )

- **Conséquence** : la solution  $\hat{\theta}$  est calculée par des méthodes itératives (Gauss Newton, Gradient, ...)
- **Problème majeur** : estimer un **minimum local** (*initialisation très importante*)

## Prédicteur pour un modèle OE

- L'estimée  $\hat{\theta}$  est solution de :

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{N} \sum_{t=1}^N (y(t_k) - \varphi^T(t_k, \theta))^2}_{V(\theta, Z^N)}$$

- **Difficulté** : le minimum du critère est atteint lorsque la dérivée s'annule :

$$\left. \frac{\partial V_N(\theta, Z^N)}{\partial \theta} \right|_{\theta=\hat{\theta}} = 0$$

or la dérivée est une expression compliquée non linéaire en  $\theta$

$\implies$  Présence de plusieurs minima locaux (la dérivée s'annule pour plusieurs valeurs de  $\theta$ )

- **Conséquence** : la solution  $\hat{\theta}$  est calculée par des méthodes itératives (Gauss Newton, Gradient, ...)
- **Problème majeur** : estimer un **minimum local** (*initialisation très importante*)

## Prédicteur pour un modèle OE

- L'estimée  $\hat{\theta}$  est solution de :

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{N} \sum_{t=1}^N (y(t_k) - \varphi^T(t_k, \theta))^2}_{V(\theta, Z^N)}$$

- **Difficulté** : le minimum du critère est atteint lorsque la dérivée s'annule :

$$\left. \frac{\partial V_N(\theta, Z^N)}{\partial \theta} \right|_{\theta=\hat{\theta}} = 0$$

or la dérivée est une expression compliquée non linéaire en  $\theta$

$\implies$  Présence de plusieurs minima locaux (la dérivée s'annule pour plusieurs valeurs de  $\theta$ )

- **Conséquence** : la solution  $\hat{\theta}$  est calculée par des méthodes itératives (Gauss Newton, Gradient, ...)
- **Problème majeur** : estimer un **minimum local** (*initialisation très importante*)

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- **Définitions**
- Propriétés statistiques des moindres carrés
- Bilan



## Propriétés statistiques des estimateurs

- Etablir les propriétés asymptotiques pour un nombre de données  $N$  fini est un problème difficile et complexe
- Solution simplificatrice retenue : écriture des propriétés asymptotiques de  $\hat{\theta}_N$  lorsque  $N$  tend vers l'infini,  $\rightarrow$  propriétés asymptotiques
- Du fait de la présence du bruit stochastique  $v(t_k)$  sur les données d'E/S  $Z^N$ , le vecteur des paramètres estimés  $\theta_N$  est une variable aléatoire.
- Conséquence : l'estimée  $\theta_N$  est différente d'un jeu de données à l'autre (suivant la réalisation du bruit présent sur les données)
- L'objectif de l'estimateur : estimer les paramètres les plus "proches" possibles des paramètres vrais,  $\forall$  la réalisation du bruit ,

## Propriétés statistiques des estimateurs

- Etablir les propriétés asymptotiques pour un nombre de données  $N$  fini est un problème difficile et complexe
- Solution simplificatrice retenue : écriture des propriétés asymptotiques de  $\hat{\theta}_N$  lorsque  $N$  tend vers l'infini,  $\rightarrow$  propriétés asymptotiques
- Du fait de la présence du bruit stochastique  $v(t_k)$  sur les données d'E/S  $Z^N$ , le vecteur des paramètres estimés  $\theta_N$  est une variable aléatoire.
- Conséquence : l'estimée  $\theta_N$  est différente d'un jeu de données à l'autre (suivant la réalisation du bruit présent sur les données)
- L'objectif de l'estimateur : estimer les paramètres les plus "proches" possibles des paramètres vrais,  $\forall$  la réalisation du bruit ,

## Propriétés statistiques des estimateurs

- Etablir les propriétés asymptotiques pour un nombre de données  $N$  fini est un problème difficile et complexe
- Solution simplificatrice retenue : écriture des propriétés asymptotiques de  $\hat{\theta}_N$  lorsque  $N$  tend vers l'infini,  $\rightarrow$  propriétés asymptotiques
- Du fait de la présence du bruit stochastique  $v(t_k)$  sur les données d'E/S  $Z^N$ , le vecteur des paramètres estimés  $\theta_N$  est une variable aléatoire.
- Conséquence : l'estimée  $\theta_N$  est différente d'un jeu de données à l'autre (suivant la réalisation du bruit présent sur les données)
- L'objectif de l'estimateur : estimer les paramètres les plus "proches" possibles des paramètres vrais,  $\forall$  la réalisation du bruit ,

## Propriétés statistiques des estimateurs

- Etablir les propriétés asymptotiques pour un nombre de données  $N$  fini est un problème difficile et complexe
- Solution simplificatrice retenue : écriture des propriétés asymptotiques de  $\hat{\theta}_N$  lorsque  $N$  tend vers l'infini,  $\rightarrow$  propriétés asymptotiques
- Du fait de la présence du bruit stochastique  $v(t_k)$  sur les données d'E/S  $Z^N$ , le vecteur des paramètres estimés  $\theta_N$  est une variable aléatoire.
- Conséquence : l'estimée  $\theta_N$  est différente d'un jeu de données à l'autre (suivant la réalisation du bruit présent sur les données)
- L'objectif de l'estimateur : estimer les paramètres les plus "proches" possibles des paramètres vrais,  $\forall$  la réalisation du bruit ,

## Propriétés statistiques des estimateurs

- Etablir les propriétés asymptotiques pour un nombre de données  $N$  fini est un problème difficile et complexe
- Solution simplificatrice retenue : écriture des propriétés asymptotiques de  $\hat{\theta}_N$  lorsque  $N$  tend vers l'infini,  $\rightarrow$  propriétés asymptotiques
- Du fait de la présence du bruit stochastique  $v(t_k)$  sur les données d'E/S  $Z^N$ , le vecteur des paramètres estimés  $\theta_N$  est une variable aléatoire.
- Conséquence : l'estimée  $\theta_N$  est différente d'un jeu de données à l'autre (suivant la réalisation du bruit présent sur les données)
- L'objectif de l'estimateur : estimer les paramètres les plus "proches" possibles des paramètres vrais,  $\forall$  la réalisation du bruit ,

## Propriétés statistiques des estimateurs

Objectif : définir un estimateur présentant les propriétés suivantes :

- Estimateur *non biaisé* (unbiased) :

$$E(\hat{\theta}_N) = \theta_0, \hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta)$$

où  $P_\theta$  est la matrice de covariance

- Estimateur *convergent* (consistent) :  $\hat{\theta}_N$  est consistant si

$$\diamond \Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$$


$$\diamond \hat{\theta}_N \longrightarrow \theta_0 \text{ avec probabilité 1 pour } N \longrightarrow \infty$$

- Variance* : (minimale si possible)


$$\text{cov}(\hat{\theta}_N) = E(\hat{\theta}_N - E(\hat{\theta}_N))(\hat{\theta}_N - E(\hat{\theta}_N))^T$$

## Illustration du biais d'un estimateur

- Comparaison du biais de deux estimateurs



(a) Estimateur A



(b) Estimateur B

- La moyenne des tirs pour l'estimateur A n'est pas au cœur de la cible (erreur systématique = biais) contrairement à l'estimateur B pour lequel la moyenne des tirs correspond au centre de la cible (**estimateur B sans biais**).

## Interprétation de $\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta)$

- Supposons que l'on puisse répéter  $p$  expériences de  $N$  données sur le système, donnant lieu à  $p$  estimées différentes  $\hat{\theta}_N^{(i)}$ , pour  $i \in [1, p]$ , alors

$$\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta) \quad (11)$$

$$\Downarrow \quad (12)$$

$$P_\theta = E((\hat{\theta}_N - \theta_0)(\hat{\theta}_N - \theta_0)^T) \quad (13)$$

- La matrice de covariance des paramètres  $P_\theta$  :
  - ◇ est une mesure des fluctuations des estimées autour de la valeur vraie
  - ◇ dépend du signal d'entrée  $u(t_k)$  et du nombre  $N$  de données
- Elle permet d'évaluer la variance de l'estimateur
  - ◇ un estimateur à variance minimale est dit précis
- Objectifs recherchés :
  - ◇ estimateur sans biais et à variance minimale  
 $\implies$  estimateur optimal



## Interprétation de $\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta)$

- Supposons que l'on puisse répéter  $p$  expériences de  $N$  données sur le système, donnant lieu à  $p$  estimées différentes  $\hat{\theta}_N^{(i)}$ , pour  $i \in [1, p]$ , alors

$$\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta) \quad (11)$$

$$\Downarrow \quad (12)$$

$$P_\theta = E((\hat{\theta}_N - \theta_0)(\hat{\theta}_N - \theta_0)^T) \quad (13)$$

- La matrice de covariance des paramètres  $P_\theta$  :
  - ◇ est une mesure des fluctuations des estimées autour de la valeur vraie
  - ◇ dépend du signal d'entrée  $u(t_k)$  et du nombre  $N$  de données
- Elle permet d'évaluer la variance de l'estimateur
  - ◇ un estimateur à variance minimale est dit précis
- Objectifs recherchés :
  - ◇ estimateur sans biais et à variance minimale  
 $\implies$  estimateur optimal

## Interprétation de $\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta)$

- Supposons que l'on puisse répéter  $p$  expériences de  $N$  données sur le système, donnant lieu à  $p$  estimées différentes  $\hat{\theta}_N^{(i)}$ , pour  $i \in [1, p]$ , alors

$$\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta) \quad (11)$$

$$\Downarrow \quad (12)$$

$$P_\theta = E((\hat{\theta}_N - \theta_0)(\hat{\theta}_N - \theta_0)^T) \quad (13)$$

- La matrice de covariance des paramètres  $P_\theta$  :
  - ◇ est une mesure des fluctuations des estimées autour de la valeur vraie
  - ◇ dépend du signal d'entrée  $u(t_k)$  et du nombre  $N$  de données
- Elle permet d'évaluer la variance de l'estimateur
  - ◇ un estimateur à variance minimale est dit précis
- Objectifs recherchés :
  - ◇ estimateur sans biais et à variance minimale  
 $\implies$  estimateur optimal

## Interprétation de $\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta)$

- Supposons que l'on puisse répéter  $p$  expériences de  $N$  données sur le système, donnant lieu à  $p$  estimées différentes  $\hat{\theta}_N^{(i)}$ , pour  $i \in [1, p]$ , alors

$$\hat{\theta}_N \sim \mathcal{N}(\theta_0, P_\theta) \quad (11)$$


$$\Downarrow \quad (12)$$

$$P_\theta = E((\hat{\theta}_N - \theta_0)(\hat{\theta}_N - \theta_0)^T) \quad (13)$$


- La matrice de covariance des paramètres  $P_\theta$  :
  - ◇ est une mesure des fluctuations des estimées autour de la valeur vraie
  - ◇ dépend du signal d'entrée  $u(t_k)$  et du nombre  $N$  de données
- Elle permet d'évaluer la variance de l'estimateur
  - ◇ un estimateur à variance minimale est dit précis
- Objectifs recherchés :
  - ◇ **estimateur sans biais et à variance minimale**  
 $\implies$  **estimateur optimal**

## Illustration de la variance d'un estimateur

- Comparaison de la variance de deux estimateurs



(c) Estimateur A




(d) Estimateur B


- Les deux estimateurs sont sans biais (moyenne des tirs au cœur de la cible)
- L'estimateur B est plus précis (variance plus faible) que l'estimateur A  
 $\Rightarrow$  **estimateur B = estimateur optimal**

## Illustration de la variance d'un estimateur

- Comparaison de la variance de deux estimateurs



(e) Estimateur A




(f) Estimateur B


- Les deux estimateurs sont sans biais (moyenne des tirs au cœur de la cible)
- L'estimateur B est plus précis (variance plus faible) que l'estimateur A  
 $\Rightarrow$  **estimateur B = estimateur optimal**

## Illustration de la variance d'un estimateur

- Comparaison de la variance de deux estimateurs



(g) Estimateur A



(h) Estimateur B

- Les deux estimateurs sont sans biais (moyenne des tirs au cœur de la cible)
- L'estimateur B est plus précis (variance plus faible) que l'estimateur A  
 $\Rightarrow$  **estimateur B = estimateur optimal**

## Interprétation de $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$

- $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$  s'écrit aussi :

- ◇  $p \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0$

- ◇ ou encore  $\lim_{N \rightarrow \infty} P(\|\hat{\theta}_N - \theta_0\| < \varepsilon) = 0$

L'estimateur est **convergent** en probabilité

- Si l'on pouvait acquérir une **infinité de données** ( $N \rightarrow \infty$ ), le vecteur des paramètres estimés aurait la distribution suivante :

$$\hat{\theta}_{N \rightarrow \infty} \sim \mathcal{N}(\theta_0, P_\theta) \text{ avec } P_\theta = 0$$

- Remarque

- ◇ si le biais et la variance de l'estimateur tendent asymptotiquement (pour  $N \rightarrow \infty$ ) vers 0, alors l'estimateur est **convergent**

## Interprétation de $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$

- $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$  s'écrit aussi :

- ◇  $p \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0$

- ◇ ou encore  $\lim_{N \rightarrow \infty} P(\|\hat{\theta}_N - \theta_0\| < \varepsilon) = 1$

L'estimateur est **convergent** en probabilité

- Si l'on pouvait acquérir une **infinité de données** ( $N \rightarrow \infty$ ), le vecteur des paramètres estimés aurait la distribution suivante :

$$\hat{\theta}_{N \rightarrow \infty} \sim \mathcal{N}(\theta_0, P_\theta) \text{ avec } P_\theta = 0$$

- Remarque

- ◇ si le biais et la variance de l'estimateur tendent asymptotiquement (pour  $N \rightarrow \infty$ ) vers 0, alors l'estimateur est **convergent**



## Interprétation de $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$

- $Pr \left[ \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0 \right] = 1$  s'écrit aussi :

- ◇  $p \lim_{N \rightarrow \infty} \hat{\theta}_N = \theta_0$

- ◇ ou encore  $\lim_{N \rightarrow \infty} P(\|\hat{\theta}_N - \theta_0\| < \varepsilon) = 0$

L'estimateur est **convergent** en probabilité

- Si l'on pouvait acquérir une **infinité de données** ( $N \rightarrow \infty$ ), le vecteur des paramètres estimés aurait la distribution suivante :

$$\hat{\theta}_{N \rightarrow \infty} \sim \mathcal{N}(\theta_0, P_\theta) \text{ avec } P_\theta = 0$$

- Remarque
  - ◇ si le biais et la variance de l'estimateur tendent asymptotiquement (pour  $N \rightarrow \infty$ ) vers 0, alors l'estimateur est **convergent**

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

## Propriétés statistiques des moindres carrés

- Pour établir les propriétés asymptotiques (biais, variance) de l'estimateur des MC, il faut formuler une hypothèse sur le système "vrai" ayant généré les données. On suppose que :

$$\mathcal{S} : y(t_k) = \varphi^T(t_k)\theta_0 + v(t_k)$$

- Le vecteur des paramètres estimés par MC (modèle) s'écrit :

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) y(t_k) \quad (14)$$

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) (\varphi(t_k)^T \theta_0 + v(t_k)) \quad (15)$$

$$\hat{\theta}_{mc} = \theta_0 + \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) v(t_k) \quad (16)$$

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$

## Propriétés statistiques des moindres carrés

- Pour établir les propriétés asymptotiques (biais, variance) de l'estimateur des MC, il faut formuler une hypothèse sur le système "vrai" ayant généré les données. On suppose que :

$$\mathcal{S} : y(t_k) = \varphi^T(t_k)\theta_0 + v(t_k)$$

- Le vecteur des paramètres estimés par MC (modèle) s'écrit :

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) y(t_k) \quad (14)$$

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) (\varphi(t_k)^T \theta_0 + v(t_k)) \quad (15)$$

$$\hat{\theta}_{mc} = \theta_0 + \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) v(t_k) \quad (16)$$

• Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$

## Propriétés statistiques des moindres carrés

- Pour établir les propriétés asymptotiques (biais, variance) de l'estimateur des MC, il faut formuler une hypothèse sur le système "vrai" ayant généré les données. On suppose que :

$$\mathcal{S} : y(t_k) = \varphi^T(t_k)\theta_0 + v(t_k)$$

- Le vecteur des paramètres estimés par MC (modèle) s'écrit :

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) y(t_k) \quad (14)$$

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) (\varphi(t_k)^T \theta_0 + v(t_k)) \quad (15)$$

$$\hat{\theta}_{mc} = \theta_0 + \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) v(t_k) \quad (16)$$

• Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E[\varphi(t_k) \varphi^T(t_k)]^{-1} E[\varphi(t_k) v(t_k)]$

## Propriétés statistiques des moindres carrés

- Pour établir les propriétés asymptotiques (biais, variance) de l'estimateur des MC, il faut formuler une hypothèse sur le système "vrai" ayant généré les données. On suppose que :

$$\mathcal{S} : y(t_k) = \varphi^T(t_k)\theta_0 + v(t_k)$$

- Le vecteur des paramètres estimés par MC (modèle) s'écrit :

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) y(t_k) \quad (14)$$

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) (\varphi(t_k)^T \theta_0 + v(t_k)) \quad (15)$$

$$\hat{\theta}_{mc} = \theta_0 + \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) v(t_k) \quad (16)$$

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$

## Propriétés statistiques des moindres carrés

- Pour établir les propriétés asymptotiques (biais, variance) de l'estimateur des MC, il faut formuler une hypothèse sur le système "vrai" ayant généré les données. On suppose que :

$$\mathcal{S} : y(t_k) = \varphi^T(t_k)\theta_0 + v(t_k)$$

- Le vecteur des paramètres estimés par MC (modèle) s'écrit :

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) y(t_k) \quad (14)$$

$$\hat{\theta}_{mc} = \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) (\varphi(t_k)^T \theta_0 + v(t_k)) \quad (15)$$

$$\hat{\theta}_{mc} = \theta_0 + \left[ \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right]^{-1} \sum_{k=1}^N \varphi(t_k) v(t_k) \quad (16)$$

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$

## Biais de l'estimateur des moindres carrés

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$

- L'estimateur des moindres carrés sera convergent ssi

- ①  $E [\varphi(t_k) \varphi^T(t_k)]$  est non singulière

- ②  $E [\varphi(t_k) v(t_k)] = 0$

- La 1ère condition est souvent vérifiée (sous condition de signal d'excitation d'ordre suffisant et période d'échantillonnage adéquate)

- La 2nde condition n'est quasi jamais vérifiée !

SAUF si  $v(t_k) = e(t_k)$  est un bruit blanc,  
donc si le modèle recherché est de structure  
ARX !

- En général, l'estimateur des moindres carrés n'est pas convergent (toujours biaisé), sauf si le bruit  $v(t_k)$  est un bruit blanc (structure ARX).



## Biais de l'estimateur des moindres carrés

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$
  - L'estimateur des moindres carrés sera convergent ssi
    - 1  $E [\varphi(t_k) \varphi^T(t_k)]$  est non singulière
    - 2  $E [\varphi(t_k) v(t_k)] = 0$ 
      - ◇ La 1ère condition est souvent vérifiée (sous condition de signal d'excitation d'ordre suffisant et période d'échantillonnage adéquate)
      - ◇ La 2nde condition n'est quasi jamais vérifiée !
- SAUF si  $v(t_k) = e(t_k)$  est un bruit blanc,  
donc si le modèle recherché est de structure  
ARX !
- En général, l'estimateur des moindres carrés n'est pas convergent (toujours biaisé), sauf si le bruit  $v(t_k)$  est un bruit blanc (structure ARX).

## Biais de l'estimateur des moindres carrés

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k)\varphi^T(t_k)]^{-1} E [\varphi(t_k)v(t_k)]$
  - L'estimateur des moindres carrés sera convergent ssi
    - 1  $E [\varphi(t_k)\varphi^T(t_k)]$  est non singulière
    - 2  $E [\varphi(t_k)v(t_k)] = 0$ 
      - ◇ La 1ère condition est souvent vérifiée (sous condition de signal d'excitation d'ordre suffisant et période d'échantillonnage adéquate)
      - ◇ La 2nde condition n'est quasi jamais vérifiée !
- SAUF si  $v(t_k) = e(t_k)$  est un bruit blanc,  
donc si le modèle recherché est de structure  
ARX !
- En général, l'estimateur des moindres carrés n'est pas convergent (toujours biaisé), sauf si le bruit  $v(t_k)$  est un bruit blanc (structure ARX).


## Biais de l'estimateur des moindres carrés

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$
  - L'estimateur des moindres carrés sera convergent ssi
    - 1  $E [\varphi(t_k) \varphi^T(t_k)]$  est non singulière
    - 2  $E [\varphi(t_k) v(t_k)] = 0$ 
      - ◇ La 1ère condition est souvent vérifiée (sous condition de signal d'excitation d'ordre suffisant et période d'échantillonnage adéquate)
      - ◇ La 2nde condition n'est quasi jamais vérifiée !
- SAUF si  $v(t_k) = e(t_k)$  est un bruit blanc,  
donc si le modèle recherché est de structure  
ARX !
- En général, l'estimateur des moindres carrés n'est pas convergent (toujours biaisé), sauf si le bruit  $v(t_k)$  est un bruit blanc (structure ARX).

## Biais de l'estimateur des moindres carrés

- Lorsque  $N \rightarrow \infty$ ,  $\hat{\theta}_{mc} - \theta_0 = E [\varphi(t_k) \varphi^T(t_k)]^{-1} E [\varphi(t_k) v(t_k)]$
- L'estimateur des moindres carrés sera convergent ssi
  - 1  $E [\varphi(t_k) \varphi^T(t_k)]$  est non singulière
  - 2  $E [\varphi(t_k) v(t_k)] = 0$
- ◇ La 1ère condition est souvent vérifiée (sous condition de signal d'excitation d'ordre suffisant et période d'échantillonnage adéquate)
- ◇ La 2nde condition n'est quasi jamais vérifiée !

SAUF si  $v(t_k) = e(t_k)$  est un bruit blanc,  
donc si le modèle recherché est de structure  
ARX !



- En général, l'estimateur des moindres carrés n'est pas convergent (toujours biaisé), sauf si le bruit  $v(t_k)$  est un bruit blanc (structure ARX).

## Varianse de l'estimateur des moindres carrés

- Matrice de covariance des paramètres :

- ◇ mesure des fluctuations des estimés autour de la valeur vraie.

$$\text{cov}(\hat{\theta}_N) = P_{\hat{\theta}_N} = P \left[ (\hat{\theta}_N - \theta_0) (\hat{\theta}_N - \theta_0)^T \right]$$

- ◇ Calcul de la variance à partir de l'écriture matricielle. Soit

$$\hat{\theta}_N = \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N$$

## Varianse de l'estimateur des moindres carrés

- Matrice de covariance des paramètres :

- ◇ mesure des fluctuations des estimés autour de la valeur vraie.

$$\text{cov}(\hat{\theta}_N) = P_{\hat{\theta}_N} = P \left[ (\hat{\theta}_N - \theta_0) (\hat{\theta}_N - \theta_0)^T \right]$$

- ◇ Calcul de la variance à partir de l'écriture matricielle. Soit

$$\hat{\theta}_N = \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N$$

## Varianse de l'estimateur des moindres carrés

- Matrice de covariance des paramètres :

- ◇ mesure des fluctuations des estimés autour de la valeur vraie.

$$\text{cov}(\hat{\theta}_N) = P_{\hat{\theta}_N} = P \left[ (\hat{\theta}_N - \theta_0) (\hat{\theta}_N - \theta_0)^T \right]$$

- ◇ Calcul de la variance à partir de l'écriture matricielle. Soit

$$\hat{\theta}_N = \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N$$

On en déduit :

$$\begin{aligned} \hat{\theta}_N - \theta_0 &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N - \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \Phi_N \theta_0 \\ &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T (Y_N - \Phi_N \theta_0) \\ &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \end{aligned}$$

## Variane de l'estimateur des moindres carrés

- Matrice de covariance des paramètres :

- ◇ mesure des fluctuations des estimés autour de la valeur vraie.

$$\text{cov}(\hat{\theta}_N) = P_{\hat{\theta}_N} = P \left[ (\hat{\theta}_N - \theta_0) (\hat{\theta}_N - \theta_0)^T \right]$$

- ◇ Calcul de la variance à partir de l'écriture matricielle. Soit

$$\hat{\theta}_N = \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N$$

On en déduit :

$$\begin{aligned} \hat{\theta}_N - \theta_0 &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T Y_N - \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \Phi_N \theta_0 \\ &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T (Y_N - \Phi_N \theta_0) \\ &= \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \end{aligned}$$

On reporte dans l'équation de la variance :

$$\text{cov}(\hat{\theta}_N) = E \left[ \left( \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \right) \left( \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \right)^T \right]$$



## Varianze de l'estimateur des moindres carrés

- Matrice de covariance des paramètres (suite) :

- ◆ Suite du calcul

$$\begin{aligned} \text{cov}(\hat{\theta}_N) &= E \left[ \left( \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \right) \left( \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \right)^T \right] \\ &= E \left[ \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \varepsilon_0 \varepsilon_0^T \Phi_N \left( \Phi_N^T \Phi_N \right)^{-1} \right] \\ &= \sigma_0^2 E \left[ \left( \Phi_N^T \Phi_N \right)^{-1} \Phi_N^T \Phi_N \left( \Phi_N^T \Phi_N \right)^{-1} \right] \quad \text{car } E \left[ \varepsilon_0 \varepsilon_0^T \right] = \sigma_0^2 I \\ &= \sigma_0^2 E \left[ \left( \Phi_N^T \Phi_N \right)^{-1} \right] \end{aligned}$$

- Expression développée

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right] \quad (17)$$

- En conclusion

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ \left( \Phi_N^T \Phi_N \right)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◊ est proportionnelle à la variance du bruit  $\varepsilon_0$
  - ◊ diminue avec le nombre de données
  - ◊ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◊  $\sigma_\varepsilon^2 = E [\varepsilon^2(t_k) - E[\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E[\varepsilon(t_k)] = 0$
  - ◊ D'où :  $\sigma_\varepsilon^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_\varepsilon^2}{N} R_{\varphi\varphi}^{-1}(0)$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◇  $\sigma_e^2 = E [\varepsilon^2(t_k) - E[\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E[\varepsilon(t_k)] = 0$
  - ◇ D'où :  $\sigma_e^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_e^2}{N} R_{\varphi\varphi}^{-1}(0)$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◇  $\sigma_e^2 = E [\varepsilon^2(t_k) - E[\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E[\varepsilon(t_k)] = 0$
  - ◇ D'où :  $\sigma_e^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_e^2}{N} R_{\varphi\varphi}^{-1}(0)$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◇  $\sigma_e^2 = E [\varepsilon^2(t_k) - E[\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E[\varepsilon(t_k)] = 0$
  - ◇ D'où :  $\sigma_e^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_e^2}{N} R_{\varphi\varphi}^{-1}(0)$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :

$$\diamond \sigma_\varepsilon^2 = E [\varepsilon^2(t_k) - E[\varepsilon(t_k)]^2] = E[\varepsilon^2(t_k)] \text{ car } E[\varepsilon(t_k)] = 0$$

$$\diamond \text{D'où : } \sigma_\varepsilon^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k) \quad \text{et} \quad \text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_\varepsilon^2}{N} R_{\varphi\varphi}^{-1}(0)$$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◇  $\sigma_\varepsilon^2 = E [\varepsilon^2(t_k) - E [\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E [\varepsilon(t_k)] = 0$
  - ◇ D'où :  $\sigma_\varepsilon^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_\varepsilon^2}{N} R_{\varphi\varphi}^{-1}(0)$

## Variance de l'estimateur des moindres carrés

$$\text{cov}(\hat{\theta}_N) = \sigma_0^2 E \left[ (\Phi_N^T \Phi_N)^{-1} \right] = \sigma_0^2 E \left[ \left( \frac{1}{N} \sum_{k=1}^N \varphi(t_k) \varphi^T(t_k) \right)^{-1} \right]$$

- Lorsque  $N \rightarrow \infty$ , alors :  $\text{cov}(\hat{\theta}_N) = \frac{\sigma_0^2}{N} R_{\varphi\varphi}^{-1}(0)$
- **Interprétation** : la variance des paramètres estimés par MC
  - ◇ est proportionnelle à la variance du bruit  $e_0$
  - ◇ diminue avec le nombre de données
  - ◇ le signal d'excitation  $u$  doit être "riche" afin que la matrice d'information  $R_{\varphi\varphi}(0)$  soit importante
- **En pratique**,  $\sigma_0^2$  est inconnu. Une estimée (non biaisée) peut être calculée en sachant que :
  - ◇  $\sigma_\varepsilon^2 = E [\varepsilon^2(t_k) - E [\varepsilon(t_k)]]^2] = E [\varepsilon^2(t_k)]$  car  $E [\varepsilon(t_k)] = 0$
  - ◇ D'où :  $\sigma_\varepsilon^2 = \frac{1}{N - \dim(\hat{\theta})} \sum_{k=1}^N \varepsilon^2(t_k)$  et  $\text{cov}(\hat{\theta}_N) = \frac{\hat{\sigma}_\varepsilon^2}{N} R_{\varphi\varphi}^{-1}(0)$



## Analyse des performances de l'estimateur des MC par simulation de Monte Carlo

```
B=[0 0.2];           % B(q)=0.2q-1
A=[1 -0.8];          % A(q)=1-0.8q-1
N=500;               % Nombre d'échantillons
S = idpoly(1,B,1,1,A); %y=B/Au+e - Modèle OE et non un modèle ARX – MC biaisé
u=sign(randn(N,1)); % signal d'entrée
Matrice_param_arx=[];
for i=1:200           % 200 réalisations de bruit
    randn('state',sum(100*clock));
    e=0.2*randn(N,1);
    y=sim(S,[u e]); % simulation de la sortie bruitée
    dataS= iddata(y,u); % Objet de données ayant y comme sortie et u comme entrée
    Marx=arx(dataS,[1 1 1]); % Estimation par MC des paramètres du modèle ARX
    Matrice_param_arx=[Matrice_param_arx; [Marx.B(2:end) Marx.A(2:end)]];
end
% Valeur moyenne des paramètres estimés par MC
mean(Matrice_param_arx)
0.1994    -0.5888 % Paramètre  $\hat{a}_1$  estimé : biaisé – Estimateur des MC : biaisé
% Ecart-type des paramètres estimés par MC
std(Matrice_param_arx)
0.0106     0.0222
```

# Plan

1 Introduction à l'identification de systèmes – cours 1

2 Méthodes de base – cours 2

3 Méthodes avancées – cours 3

- Choix du signal d'excitation
- Structure de modèle
- Méthodes d'estimation paramétrique
- Cas d'un modèle OE

4 Propriétés statistiques des estimateurs – cours 4

- Définitions
- Propriétés statistiques des moindres carrés
- Bilan

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

❶ Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

❶ Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

① Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

① Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

❶ Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués :

❶ Le prédicteur est une fonction **linéaire en les paramètres**

- ◇ Cas d'un modèle ARX (et FIR)
- ◇ La prédiction de la sortie s'écrit sous forme de régression linéaire

$$\hat{y}(t_k, \theta) = \varphi^T(t_k) \theta$$

- ◇ Une solution analytique existe !
- ◇ L'estimateur des moindres carrés est obtenu analytiquement, à partir des données, sans problème d'initialisation
- ◇ Propriétés statistiques de l'estimateur : estimées biaisées et asymptotiquement biaisées en général (hypothèse sur le bruit irréaliste)
- ◇ Cependant, même si les estimées par moindres carrés ne sont pas les meilleures, elle peuvent servir à initialiser des méthodes itératives



## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

### 5 Le prédicteur **n'est pas une fonction linéaire en les paramètres**

- ◇ Cas des modèles ARMAX, OE, BJ
- ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
- ◇ Une solution analytique n'existe pas !
- ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
- ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
- ◇ Problèmes :
  - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
  - ◇ Algorithmes gourmands en calculs
  - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

### 5 Le prédicteur **n'est pas une fonction linéaire en les paramètres**

- ◇ Cas des modèles ARMAX, OE, BJ
- ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
- ◇ Une solution analytique n'existe pas !
- ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
- ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
- ◇ Problèmes :
  - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
  - ◇ Algorithmes gourmands en calculs
  - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

### 5 Le prédicteur **n'est pas une fonction linéaire en les paramètres**

- ◇ Cas des modèles ARMAX, OE, BJ
- ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
- ◇ Une solution analytique n'existe pas !
- ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
- ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
- ◇ Problèmes :
  - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
  - ◇ Algorithmes gourmands en calculs
  - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

### ⑤ Le prédicteur **n'est pas une fonction linéaire en les paramètres**

- ◇ Cas des modèles ARMAX, OE, BJ
- ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
- ◇ Une solution analytique n'existe pas !
- ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
- ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
- ◇ Problèmes :
  - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
  - ◇ Algorithmes gourmands en calculs
  - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

### ⑤ Le prédicteur **n'est pas une fonction linéaire en les paramètres**

- ◇ Cas des modèles ARMAX, OE, BJ
- ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
- ◇ Une solution analytique n'existe pas !
- ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
- ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
- ◇ Problèmes :
  - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
  - ◇ Algorithmes gourmands en calculs
  - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme

## Estimation par l'erreur de prédiction – Bilan

Deux cas de figures doivent être distingués (suite) :

- ⑤ Le prédicteur **n'est pas une fonction linéaire en les paramètres**
  - ◇ Cas des modèles ARMAX, OE, BJ
  - ◇ La prédiction de la sortie ne s'écrit pas sous forme de régression linéaire
  - ◇ Une solution analytique n'existe pas !
  - ◇ Minimisation du critère effectuée à l'aide d'algorithmes numériques itératifs : gradient, Gauss-Newton, Levenberg-Marquardt,...
  - ◇ Prop. stat. des estimateurs : asymptotiquement non biaisés en général
  - ◇ Problèmes :
    - ◇ si le critère possède plusieurs minima, la méthode peut converger vers un minimum local et non vers le minimum global
    - ◇ Algorithmes gourmands en calculs
    - ◇ La convergence peut être très sensible à l'initialisation de l'algorithme